AutoML. Часть 2

Юлдуз Фаттахова
Tech Lead, Sber

Skillbox

Цели модуля

- Познакомиться с разнообразными библиотеками AutoML для подбора алгоритмов моделирования
- Разобрать, как устроены AutoML-библиотеки по подбору моделей изнутри
- Попрактиковаться в применении библиотек автоматизированного машинного обучения

Skillbox

Библиотеки для работы с AutoML

Цели видео

- Познакомиться с разнообразными библиотеками AutoML для подбора алгоритмов моделирования
- Разобраться, по каким критериям выбирать AutoML-инструменты

Основные этапы решения ML-задачи

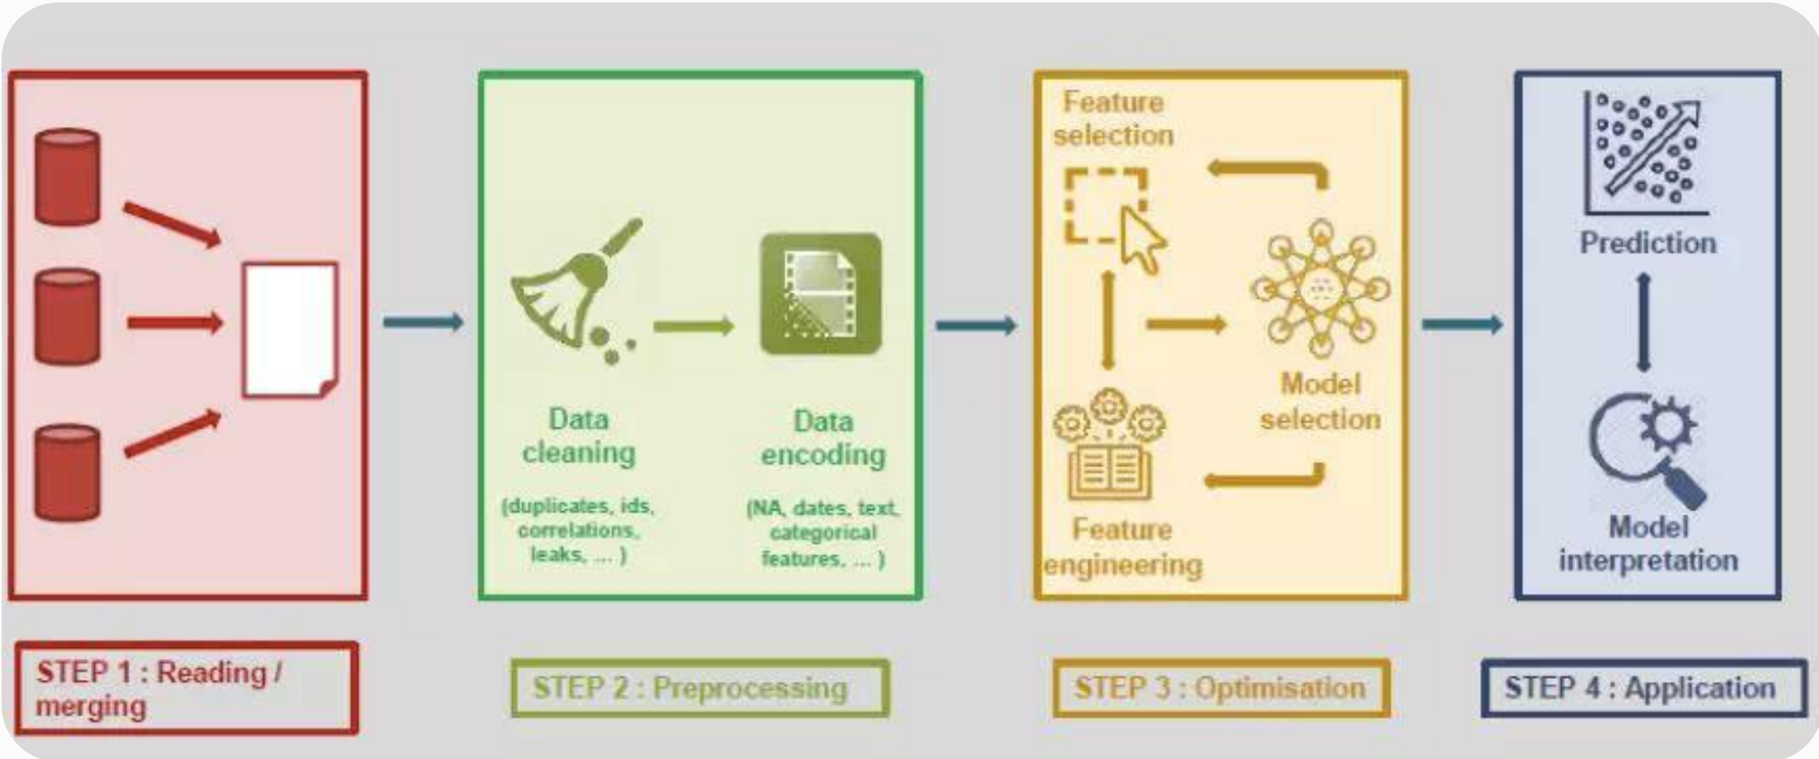

Изображение: Alibaba Cloud / alibabacloud.com

Основные этапы решения ML-задачи

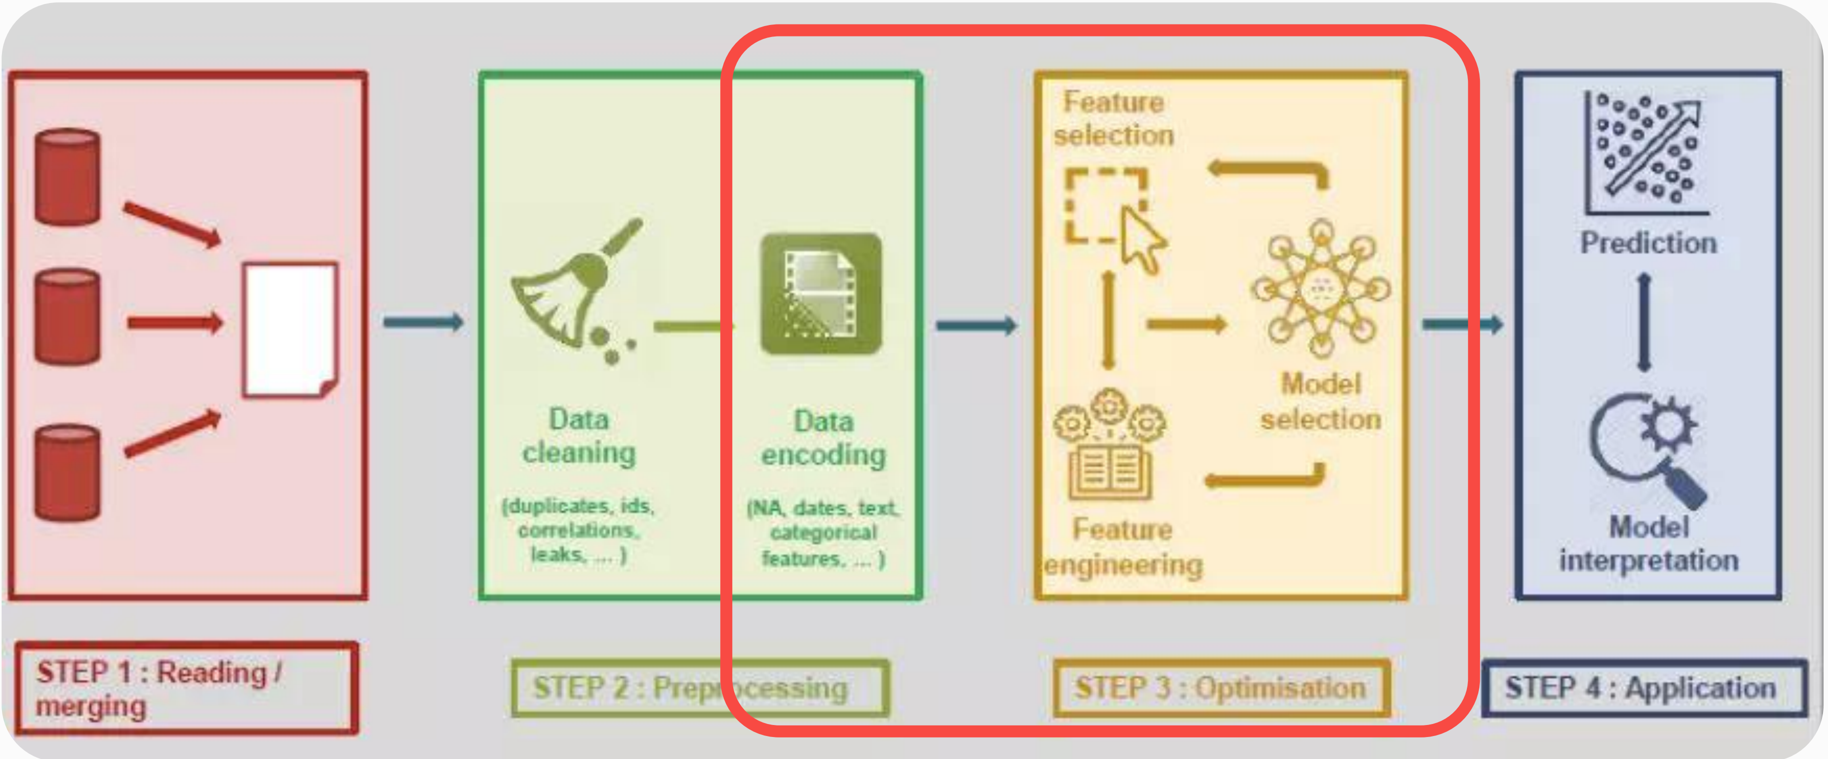

Изображение: Alibaba Cloud / alibabacloud.com

Основные задачи инструмента

- **Data Encoding**
- **Feature Selection**
- **Model Selection**
- **Hyperparameter Optimization**

Пример AutoML-инструмента — TPOT

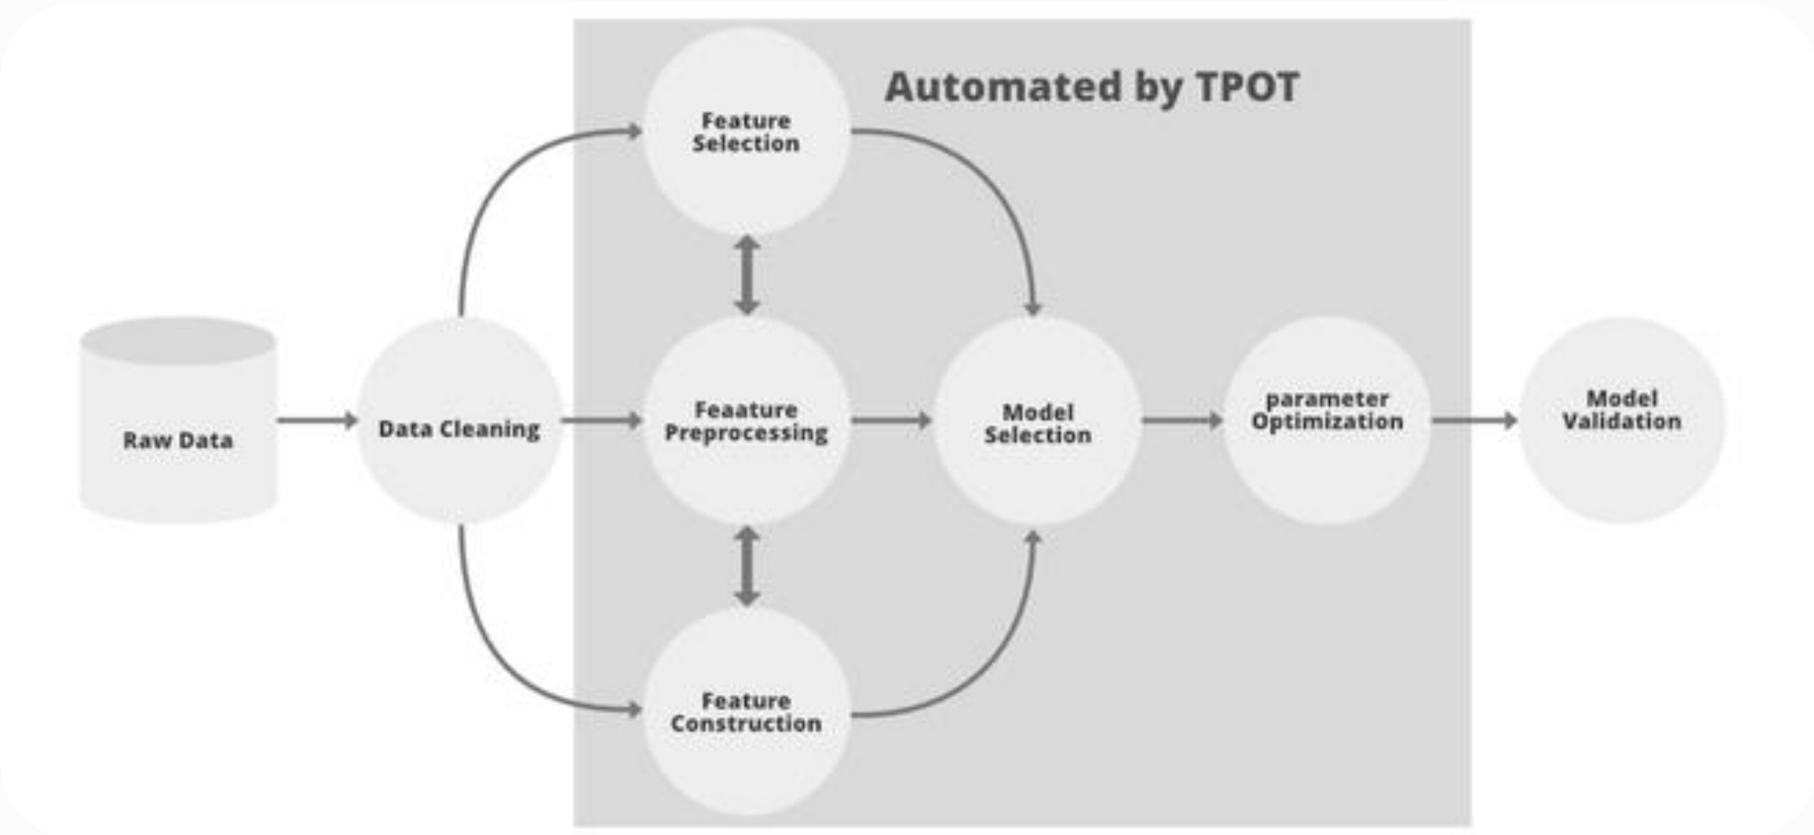

Изображение: Alibaba Cloud / alibabacloud.com

Основная идея работы с AutoML-инструментом

```
from framework import AutoML

automl = AutoML(time_budget="done by lunch")

automl.fit(X_train, y_train)

automl.predict(X_test)
```

Изображение: NORCE AS / medium.com (недоступен на территории РФ)

Зачем использовать AutoML для подбора модели?

Для упрощения работы ML-инженера и Data Scientist:

- не нужно писать много однообразного кода
- удобный понятный интерфейс работы с библиотекой
- все метрики качества на разных семействах алгоритмов хранятся в одном месте

Пример AutoML-отчётов

AutoML Leaderboard

Best model	name	model_type	metric_type	metric_value	train_time	Link
	model_1	Baseline	logloss	0.553216	0.57	Results link
	model_2	Linear	logloss	0.386093	16.86	Results link
	model_3	Decision Tree	logloss	0.37051	32.1	Results link
	model_4	Decision Tree	logloss	0.35068	38.31	Results link
	model_5	Decision Tree	logloss	0.470718	25.67	Results link
	model_35	LightGBM	logloss	0.319996	89.21	Results link
	model_24	Extra Trees	logloss	0.316764	758.36	Results link
	model_47	CatBoost	logloss	0.287799	43.44	Results link
	model_28	LightGBM	logloss	0.306792	95.62	Results link
	model_54	CatBoost	logloss	0.291674	43.83	Results link
	model_32	LightGBM	logloss	0.285343	37.26	Results link
	model_15	Random Forest	logloss	0.303293	260.59	Results link
	model_44	Xgboost	logloss	0.282967	64.23	Results link
	model_51	CatBoost	logloss	0.361852	43.54	Results link
	model_36	Xgboost	logloss	0.282682	42.8	Results link
	model_42	Xgboost	logloss	0.288004	61.22	Results link
	model_8	Random Forest	logloss	0.30142	261.95	Results link
	model_37	Xgboost	logloss	0.29182	38.75	Results link
	model_49	CatBoost	logloss	0.28389	31.79	Results link
	model_11	Random Forest	logloss	0.303303	200.62	Results link
	model_53	CatBoost	logloss	0.286871	43.73	Results link
	model_39	Xgboost	logloss	0.296138	45.37	Results link
	model_27	LightGBM	logloss	0.311163	68.87	Results link
	model_55	CatBoost	logloss	0.290329	43.68	Results link
	model_31	LightGBM	logloss	0.287866	50.21	Results link
	model_41	Xgboost	logloss	0.28635	44.36	Results link
	model_48	CatBoost	logloss	0.366781	43.65	Results link
	model_29	LightGBM	logloss	0.31711	76.78	Results link
	model_38	Xgboost	logloss	0.291679	41.4	Results link
	model_46	CatBoost	logloss	0.289934	43.92	Results link
	model_30	LightGBM	logloss	0.30651	152.52	Results link
	model_33	LightGBM	logloss	0.298923	90.55	Results link
	model_26	LightGBM	logloss	0.331075	88.7	Results link
	model_45	Xgboost	logloss	0.286455	91.6	Results link
	model_43	Xgboost	logloss	0.29637	82.26	Results link
	model_50	CatBoost	logloss	0.289398	43.63	Results link
	model_56	CatBoost	logloss	0.340194	27.88	Results link
	model_57	CatBoost	logloss	0.346185	10.35	Results link
	model_58	CatBoost	logloss	0.423313	10.47	Results link
	model_59	CatBoost	logloss	0.347703	3.38	Results link
	model_60	CatBoost	logloss	0.423381	3.53	Results link
*** the best ***	ensemble	Ensemble	logloss	0.280257	18.81	Results link

AutoML Performance

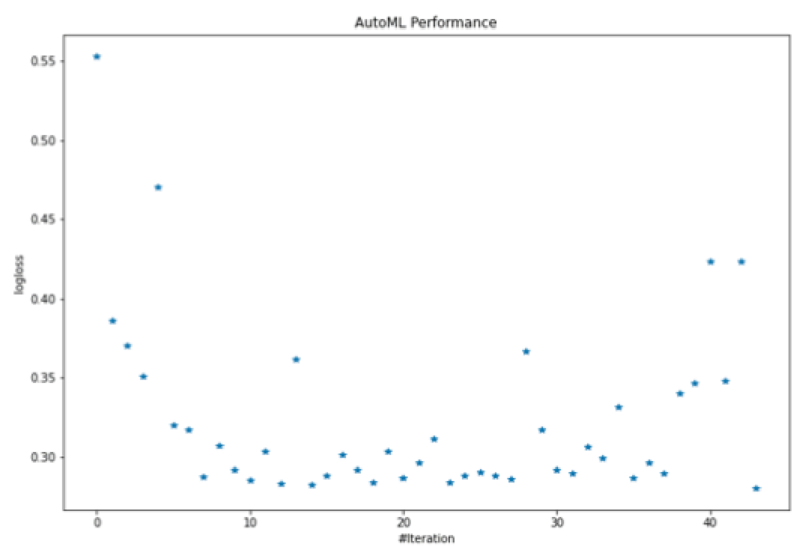

AutoML Performance Boxplot

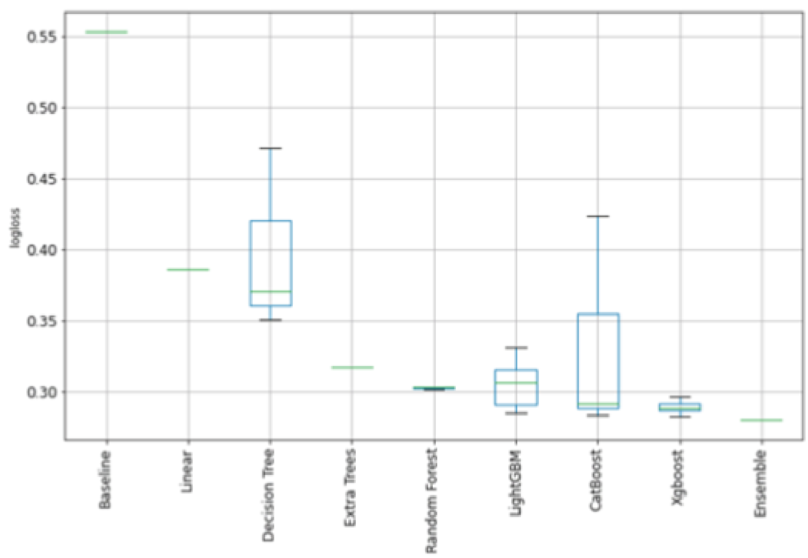

Изображение: NORCE AS / medium.com (недоступен на территории РФ)

Какие задачи решают?

Чаще всего AutoML-инструменты моделирования решают задачи обучения с учителем.

Open Source vs Proprietary

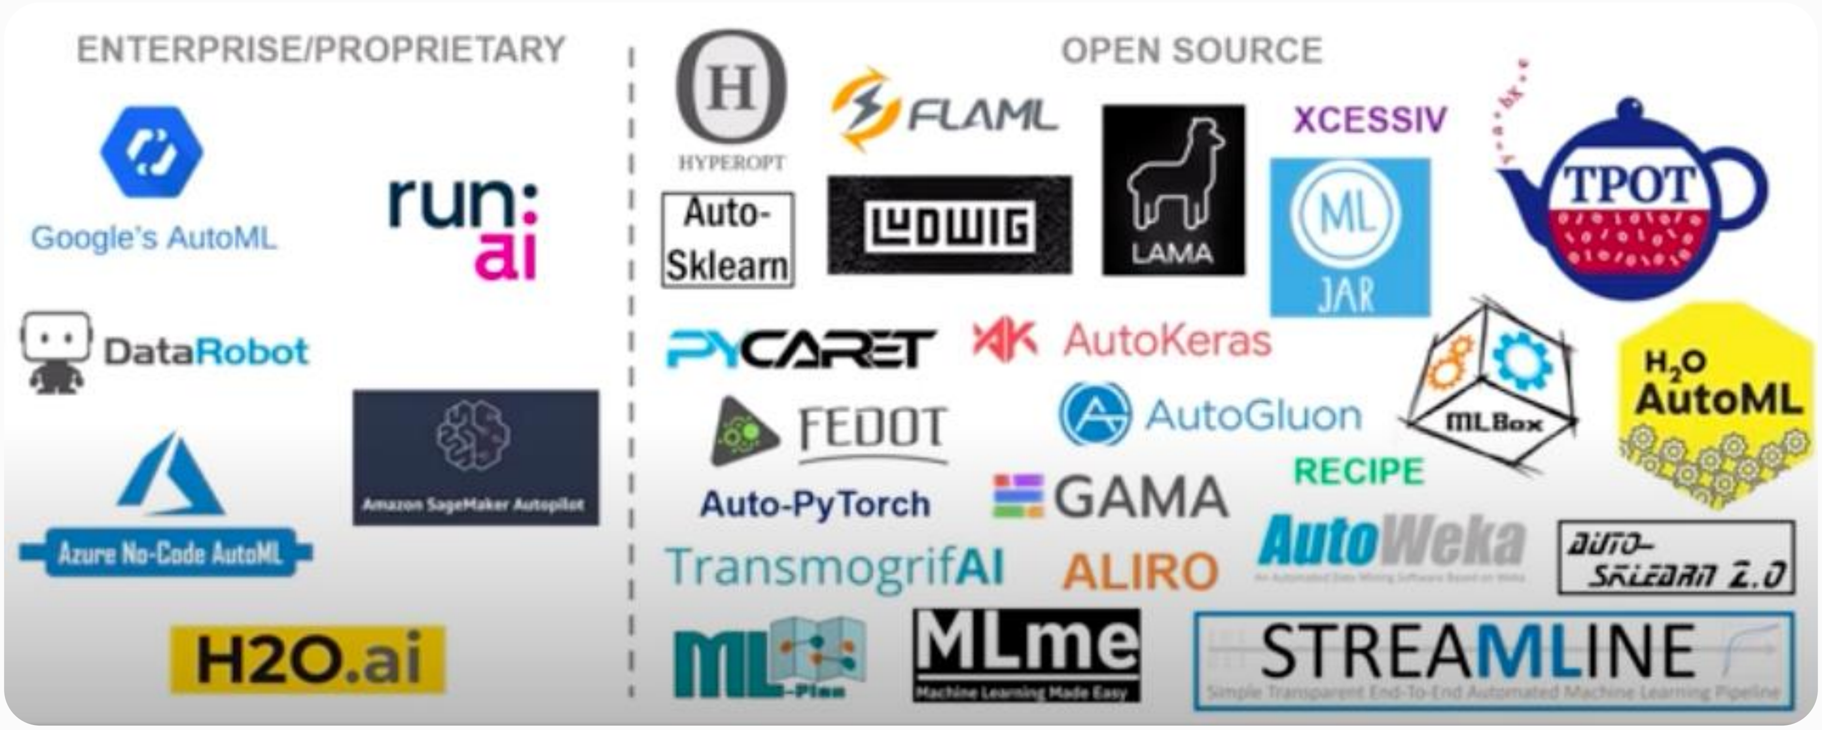

Изображение: URBS-Lab with Ryan Urbanowicz / [youtube.com]()

Как выбрать инструмент?

		Auto-Keras	H20-3 AutoML	LAMA	FLAML	PYCARET	Auto-Gluon	MLIJAR-supervised	Ludwig	TPOT	Auto-Sklearn	Auto-PyTorch	GAMA	Hyperopt-sklearn	Auto-WEKA	RECIPE	TransmogrifAI	MLBox	Auto_ML
Data Types	Structured (Tabular)	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES
	Images	YES	NO	YES	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
	Text	YES	NO	YES	YES	NO	YES	YES	NO	NO	NO	NO	NO	NO	NO	NO	YES	NO	NO
	Time-Series	YES	NO	YES	YES	NO	YES	YES	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO
	Multi-Modal	YES	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
Target	Binary Classification	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES
	MultiClass Classification	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES		YES	YES	YES
	Regression	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	NO	YES	YES	YES
	Multi-Task	YES	NO	NO	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
	Multi-Label	NO	NO	NO		NO	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO
	Clustering	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO

Изображение: Urbanowicz, R.~J. and 21 colleagues 2023.\ STREAMLINE: An Automated Machine Learning Pipeline for Biomedicine Applied to Examine the Utility of Photography-Based Phenotypes for OSA Prediction Across International Sleep Centers / arxiv.org/abs

Как выбрать инструмент?

		Auto-Keras	H20-3 AutoML	LAMA	FLAML	PYCARET	Auto-Gluon	MLJAR-supervised	Ludwig	TPOT	Auto-Sklearn	Auto-PyTorch	GAMA	Hyperopt-sklearn	Auto-WEKA	RECIPE	TransmogrifAI	MLBox	Auto_ML
Data Types	Structured (Tabular)	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES
	Images	YES	NO	YES	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
	Text	YES	NO	YES	YES	NO	YES	YES	NO	NO	NO	NO	NO	NO	NO	NO	YES	NO	NO
	Time-Series	YES	NO	YES	YES	NO	YES	YES	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO
	Multi-Modal	YES	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
Target	Binary Classification	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES
	MultiClass Classification	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES		YES	YES	YES
	Regression	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	NO	YES	YES	YES
	Multi-Task	YES	NO	NO	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
	Multi-Label	NO	NO	NO		NO	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO
	Clustering	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO

Изображение: Urbanowicz, R.~J. and 21 colleagues 2023.\ STREAMLINE: An Automated Machine Learning Pipeline for Biomedicine Applied to Examine the Utility of Photography-Based Phenotypes for OSA Prediction Across International Sleep Centers / arxiv.org/abs

Как выбрать инструмент?

		Auto-Keras	H20-3 AutoML	LAMA	FLAML	PYCARET	Auto-Gluon	MLIJAR-supervised	Ludwig	TPOT	Auto-Sklearn	Auto-PyTorch	GAMA	Hyperopt-sklearn	Auto-WEKA	RECIPE	TransmogrifAI	MLBox	Auto_ML
Data Types	Structured (Tabular)	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES
	Images	YES	NO	YES	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
	Text	YES	NO	YES	YES	NO	YES	YES	NO	NO	NO	NO	NO	NO	NO	NO	YES	NO	NO
	Time-Series	YES	NO	YES	YES	NO	YES	YES	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO
	Multi-Modal	YES	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
Target	Binary Classification	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES
	MultiClass Classification	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES		YES	YES	YES
	Regression	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	NO	YES	YES	YES
	Multi-Task	YES	NO	NO	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
	Multi-Label	NO	NO	NO		NO	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO
	Clustering	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO

Изображение: Urbanowicz, R.~J. and 21 colleagues 2023.\ STREAMLINE: An Automated Machine Learning Pipeline for Biomedicine Applied to Examine the Utility of Photography-Based Phenotypes for OSA Prediction Across International Sleep Centers / arxiv.org/abs

Как выбрать инструмент?

		Auto-Keras	H20-3 AutoML	LAMA	FLAML	PYCARET	Auto-Gluon	MLIJAR-supervised	Ludwig	TPOT	Auto-Sklearn	Auto-PyTorch	GAMA	Hyperopt-sklearn	Auto-WEKA	RECIPE	TransmogrifAI	MLBox	Auto_ML
Data Types	Structured (Tabular)	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES
	Images	YES	NO	YES	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
	Text	YES	NO	YES	YES	NO	YES	YES	NO	NO	NO	NO	NO	NO	NO	NO	YES	NO	NO
	Time-Series	YES	NO	YES	YES	NO	YES	YES	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO
	Multi-Modal	YES	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
Target	Binary Classification	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES
	MultiClass Classification	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES		YES	YES	YES
	Regression	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	NO	YES	YES	YES
	Multi-Task	YES	NO	NO	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
	Multi-Label	NO	NO	NO		NO	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO
	Clustering	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO

Изображение: Urbanowicz, R.~J. and 21 colleagues 2023.\ STREAMLINE: An Automated Machine Learning Pipeline for Biomedicine Applied to Examine the Utility of Photography-Based Phenotypes for OSA Prediction Across International Sleep Centers / arxiv.org/abs

PyCaret

ID	Name	Reference
kmeans	K-Means Clustering	sklearn.cluster._kmeans.KMeans
ap	Affinity Propagation	sklearn.cluster._affinity_propagation.Affinity...
meanshift	Mean Shift Clustering	sklearn.cluster._mean_shift.MeanShift
sc	Spectral Clustering	sklearn.cluster._spectral.SpectralClustering
hclust	Agglomerative Clustering	sklearn.cluster._agglomerative.AgglomerativeCl...
dbscan	Density-Based Spatial Clustering	sklearn.cluster._dbscan.DBSCAN
optics	OPTICS Clustering	sklearn.cluster._optics.OPTICS
birch	Birch Clustering	sklearn.cluster._birch.Birch
kmodes	K-Modes Clustering	kmodes.kmodes.KModes

Изображение: GitHub / github.com

Как выбрать инструмент?

		Auto-Keras	H20-3 AutoML	LAMA	FLAML	PYCARET	Auto-Gluon	MLIJAR-supervised	Ludwig	TPOT	Auto-Sklearn	Auto-PyTorch	GAMA	Hyperopt-sklearn	Auto-WEKA	RECIPE	TransmogrifAI	MLBox	Auto_ML
Ease of Use	Codeless Implementation	YES	YES	NO	NO	NO	NO	YES	NO	YES	YES	NO	NO	NO	YES	NO	NO	NO	NO
	Codeless Running	NO	YES	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	YES	NO	NO	NO	NO
	GUI	NO	YES	NO	NO	NO	NO	YES	NO	NO	NO	NO	YES	NO	YES	NO	NO	NO	NO
	Generates Figures/Viz	NO	NO	YES	NO	YES	NO	YES	YES	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO
	Outputs/Oranizes Results	NO	NO	NO	NO	NO	NO	YES	YES	YES	NO	NO	YES	NO	NO	NO	NO	NO	NO
	Summary Report	NO	SOME	YES	NO	YES	NO	YES	YES	NO	NO	NO	NO	NO	NO	NO	SOME	NO	NO
	Recommender System	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO
	Parallizable	YES	SOME	NO	YES	SOME	YES	NO	YES	YES	YES	YES	SOME	NO		NO	YES	NO	NO
Automated Pipeline Elements	Pipeline Config. Discovery		NO	NO	NO	NO	NO	NO	NO	YES	YES		YES	NO	NO	YES	NO	NO	NO
	Feature Extraction	N/A	NO	YES		NO		YES	NO	NO	NO	N/A	NO	NO	NO	NO	NO	NO	NO
	Exploratory Data Analysis	NO	NO	NO	NO	YES	YES	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
	Categorical Encoding	No	NO	YES	NO	YES	YES	YES	YES	NO	YES	YES	NO	NO	YES	NO	YES	NO	
	Numerical Encoding	NO	NO	YES	NO	YES	YES	YES	YES	NO	NO	NO	NO	NO		NO	NO		YES
	Basic Data Cleaning	NO	NO	NO	NO	YES	YES	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO	YES	YES
	Missing Val. Imputation	NO	NO	NO	NO	YES	YES	YES	YES	YES	YES	YES	NO	NO	NO	YES	YES	NO	
	Feature Engineering	NO	NO	YES	NO	YES	YES	YES	NO	NO	NO	NO	NO	NO	NO	YES	YES	NO	YES
	Feature Transformation	NO	NO	NO	NO	YES	NO	YES	YES	YES	YES	YES	YES	NO	NO	NO	YES	NO	YES
	Feature Learning	NO	No	NO	NO	NO	NO	YES	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	YES
	Feature Selection	NO	NO	YES	NO	YES	NO	YES	NO	YES	YES	NO	NO	NO	NO	YES	YES	YES	
	Algorithm Selection	NO	YES	SOME	YES	YES	YES	YES	NO	YES	YES	NO	YES	NO	YES	YES	YES	YES	YES
	Hyperparam. Optimization	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES	YES		NO
	Deep Learning Included	ONLY	YES	NO		NO	NO	NO	SOME	SOME	NO	ONLY	NO	NO	NO	NO	NO	YES	YES
	Models for each CV Part.	NO	NO	NO	NO	YES	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	NO		NO
	Model Evaluation	NO	YES	YES	NO	YES	YES	YES	YES	YES	YES	YES	YES	NO	NO	NO	YES	NO	NO
	Ensembling	NO	YES	YES	YES	NO	YES	YES	NO	NO	YES	YES	YES	NO	NO	NO	NO	YES	NO
	Significance Comparisons	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
	Directly Compare Datasets	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO	NO
	Replication Analysis	NO	YES	NO	NO	NO				NO	NO		NO	NO	NO	NO	NO	NO	NO
	Model Deploy (Predictions)	NO	NO	NO	NO	YES	NO	NO	YES	NO	NO	NO	NO	NO	NO	NO	NO	YES	NO

Изображение: Urbanowicz, R.~J. and 21 colleagues 2023.\ STREAMLINE: An Automated Machine Learning Pipeline for Biomedicine Applied to Examine the Utility of Photography-Based Phenotypes for OSA Prediction Across International Sleep Centers / arxiv.org/abs

Интерпретируемые модели

Black Box
Внутреннюю работу этих моделей сложнее понять: neural networks, gradient boosting models или сложные ансамбли.

White Box
Более простые модели, такие как линейная регрессия и деревья решений, обеспечивают меньшую предсказательную способность и не всегда способны моделировать присущую набору данных сложность (т. е. взаимодействие объектов). Однако, их значительно проще объяснить и интерпретировать.

Библиотеки для работы с AutoML

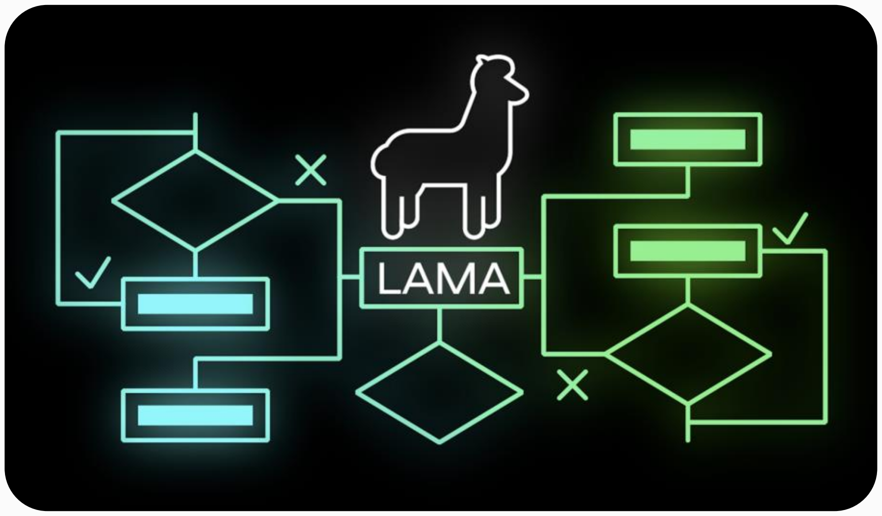

Изображения: H2O.ai / h2o.ai, mljar / mljar.com, LightAutoML / github.com, AutoGluon / auto.gluon.ai

Библиотеки для работы с AutoML

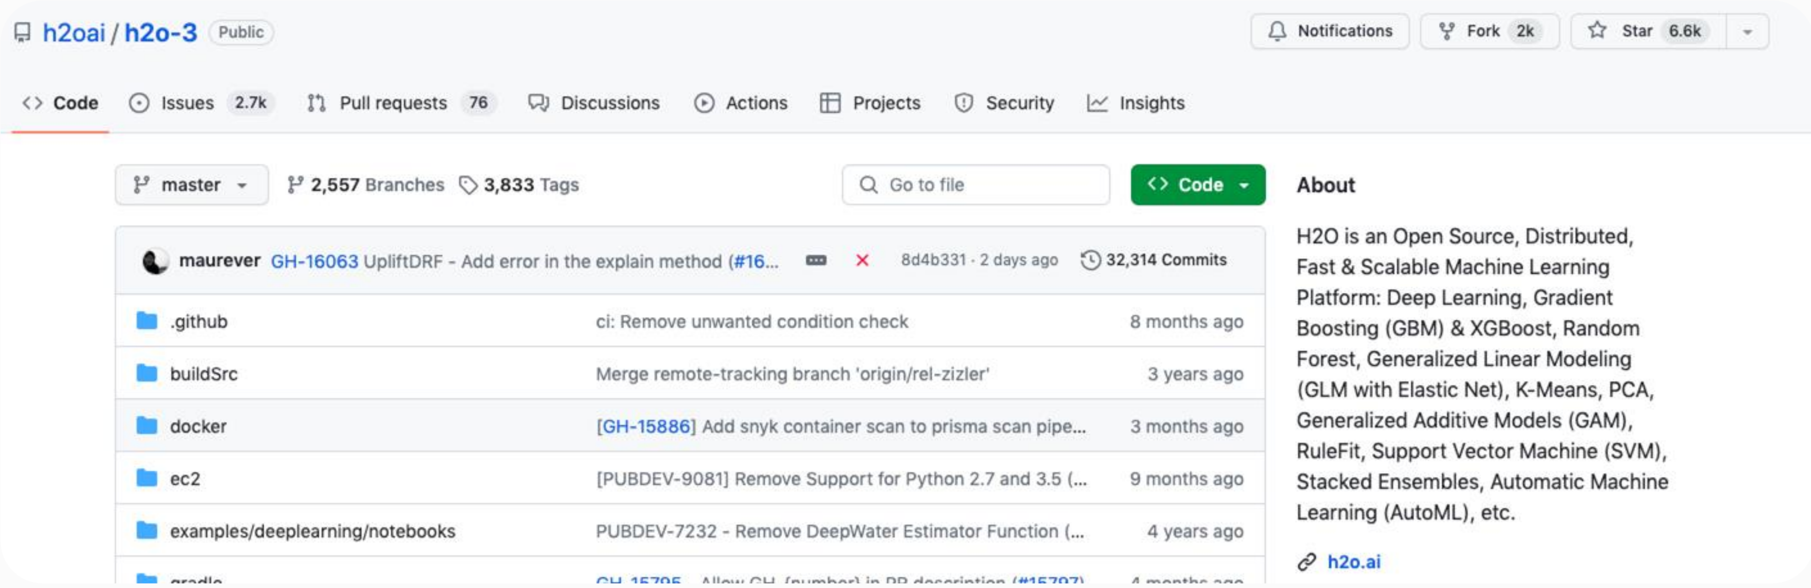

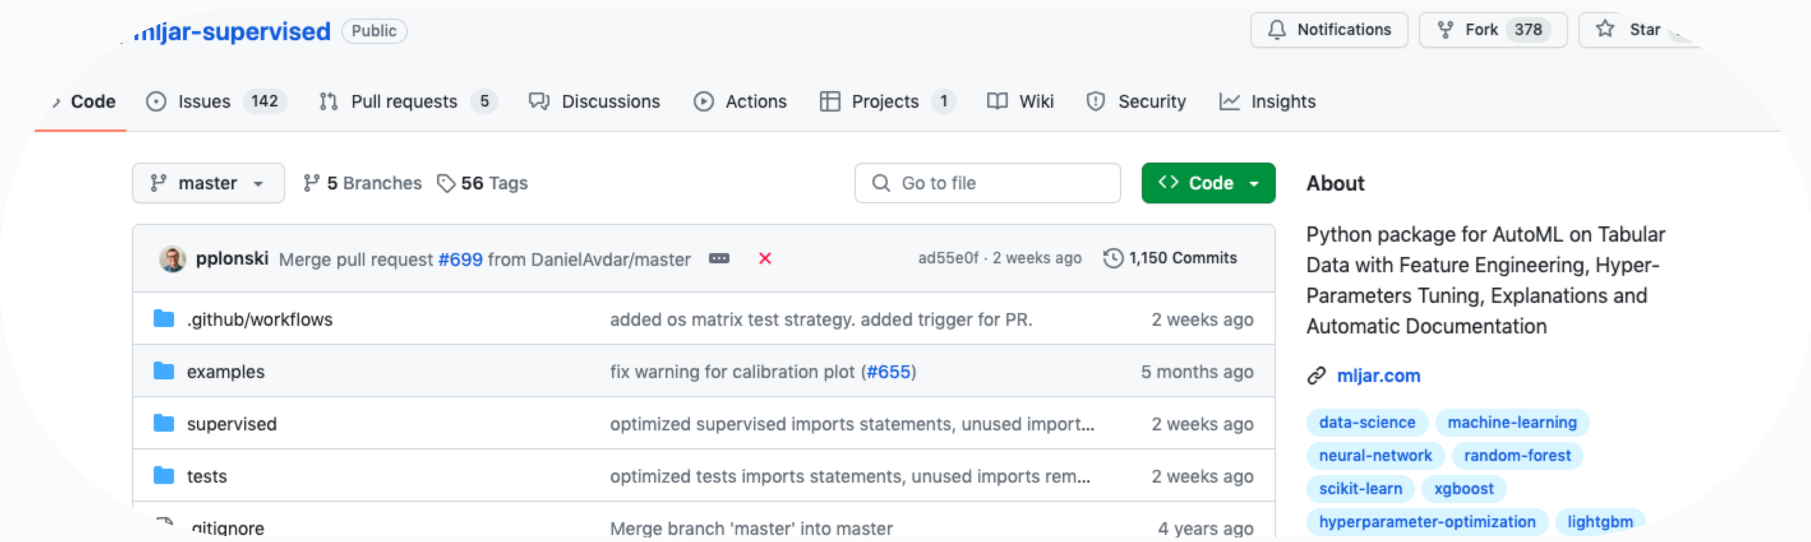

Скриншоты: H2O.ai / github.com, MLJAR / github.com

Библиотеки для работы с AutoML

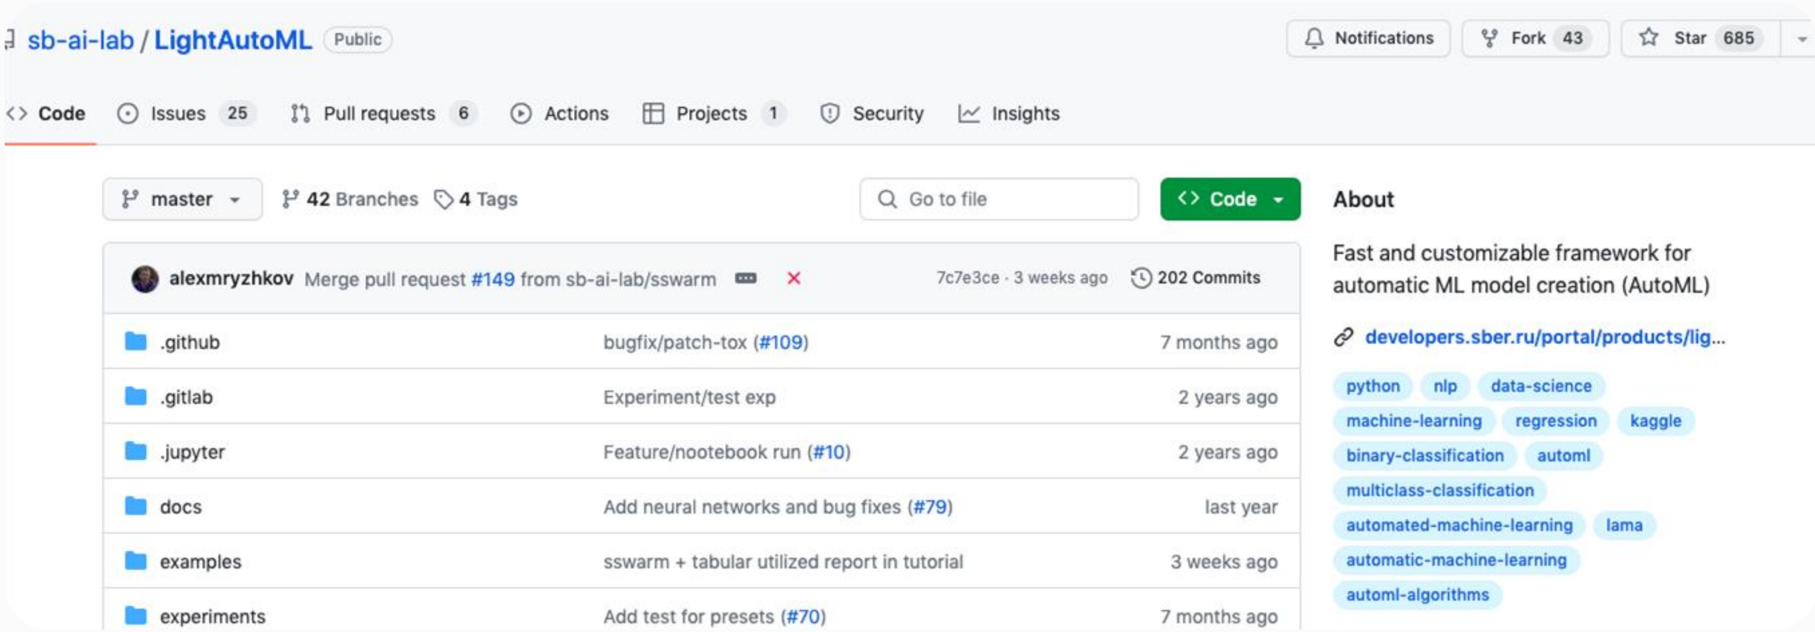

Скриншот: LightAutoML / github.com

Плюсы инструментов AutoML

Плюсы:

1. Сокращение времени на разработку
2. Сокращение времени на эксперименты
3. Переиспользование опыта лучших умов DS
4. Быстрое построение бейзлайн моделей

Плюсы и минусы инструментов AutoML

Плюсы:

1. Сокращение времени на разработку
2. Сокращение времени на эксперименты
3. Переиспользование опыта лучших умов DS
4. Быстрое построение бейзлайн моделей

Минусы:

1. Недостаточно экспертизы в узких доменных областях знаний
2. Большинство моделей не интерпретируемы
3. Долгое время обучения
4. Проблемы с кастомизацией полученных моделей

Итоги видео

- Познакомились с разнообразными библиотеками AutoML для подбора алгоритмов моделирования
- Разобрались и поняли, по каким критериям выбирать AutoML-инструменты
- Узнали, какие ограничения у использования AutoML-инструментов