


Практика работы с AutoML. Часть 1

Цели видео

- ✓ Познакомиться с внутренним устройством одной AutoML-библиотеки
- ✓ Разобрать принцип автоматического построения ML-пайплайнов для обучения

LightAutoML



LightAutoML: основные задачи

LightAutoML documentation

[LightAutoML](#) is open-source Python library aimed at automated machine learning. It is designed to be lightweight and efficient for various tasks with tabular, text data. LightAutoML provides easy-to-use pipeline creation, that enables:

- Automatic hyperparameter tuning, data processing.
- Automatic typing, feature selection.
- Automatic time utilization.
- Automatic report creation.
- Easy-to-use modular scheme to create your own pipelines.

LightAutoML и Kaggle

Linking Writing Processes to Writing Quality

Use typing behavior to predict essay quality



Overview Data Code Models Discussion Leaderboard Rules

Плюсы

- ✓ Решает задачи на больших массивах данных с помощью Spark
- ✓ Может использовать GPU
- ✓ Постоянно пополняется новыми методами, включая нейросетевые архитектуры: MLP, DenseNet, DenseLight, ResNet, SNN, TabNet, NODE, FTTransformer и AutoInt++. Также были добавлены SOTA-методы кодирования признаков — PLR и SoftEmb

Пресеты

Готовые алгоритмы решения ML-задач, включающие в себя feature selection/feature encoding/model selection/hyperparameter tuning.

Есть несколько типов пресетов:

- TabularAutoML, TabularUtilizedAutoML
- TabularCVAutoML
- TabularNLPAutoML
- WhiteBoxPreset

WhiteBox-пресет

```
[21]: sql_query = model.get_sql_inference_query('global_temp.TABLE_1')
      print(sql_query)

SELECT
  1 / (1 + EXP(-(
    -1.111
    -0.516*WOE_TAB.city
    -0.513*WOE_TAB.city_development_index
    -0.815*WOE_TAB.company_size
    -0.398*WOE_TAB.company_type
    -0.175*WOE_TAB.experience
    -0.22*WOE_TAB.enrolled_university
    -1.24*WOE_TAB.education_level
  ))) as PROB,
  WOE_TAB.*
FROM
  (SELECT
    CASE
      WHEN (city IS NULL OR LOWER(CAST(city AS VARCHAR(50))) = 'nan') THEN 0
      WHEN city IN ('city_100', 'city_102', 'city_103', 'city_116', 'city_149', 'city_159', 'city_160', 'city_45', 'city_46', 'city_64', '
      WHEN city IN ('city_104', 'city_114', 'city_136', 'city_138', 'city_16', 'city_173', 'city_23', 'city_28', 'city_36', 'city_50', 'ci
      WHEN city IN ('city_11', 'city_21', 'city_74') THEN -1.455
      ELSE -0.209
    END AS city,
    CASE
      WHEN (city_development_index IS NULL OR city_development_index = 'NaN') THEN 0
      WHEN city_development_index <= 0.6245 THEN -1.454
      WHEN city_development_index <= 0.7915 THEN -0.121
      WHEN city_development_index <= 0.9235 THEN 0.461
      ELSE 1.101
    END AS city_development_index,
    CASE
      WHEN (company_size IS NULL OR company_size = 'NaN') THEN -0.717
      WHEN company_size <= 74.0 THEN 0.221
      ELSE 0.467
    END AS company_size,
    CASE
      WHEN (company_type IS NULL OR LOWER(CAST(company_type AS VARCHAR(50))) = 'nan') THEN -0.64
      WHEN company_type IN ('Early Stage Startup', 'NGO', 'Other', 'Public Sector') THEN 0.164
      WHEN company_type = 'Funded Startup' THEN 0.737
      WHEN company_type = 'Pvt Ltd' THEN 0.398
      ELSE 0
    END AS company_type,
    ***
```

Верхнеуровневая схема




Figure 1: Main components of LightAutoML Pipeline

Верхнеуровневая схема




Figure 1: Main components of LightAutoML Pipeline

Задача Reader:

- определить типы признаков
- подготовить новые признаки
- проводить отбор признаков для моделирования


Feature selection:

Feature importances

Отсортировать в соответствии с тем, сколько раз было произведено разделение для каждого признака при построении модели градиентного бустинга.

Feature selection:

Permutation importances




For each feature column:

1. shuffle feature column
2. observe performance and compare to original

Forward selection

Forward stepwise selection example with 5 variables:



Верхнеуровневая схема




Figure 1: Main components of LightAutoML Pipeline

Верхнеуровневая схема





Figure 1: Main components of LightAutoML Pipeline


ML-пайплайн



Preprocessing block:

- подготовка непрерывных фич: нормализация, заполнение пропусков
- подготовка категориальных фич: OneHot, Label, Ordinal, Frequency или Target encoders

Пример пресета



Итоги видео

- ✓ Разобрали, как работает библиотека LightAutoML
- ✓ Разобрались с тем, что такое пресеты
- ✓ Разобрали один из пресетов для табличных данных